Asignatura	Datos del alumno	Fecha
Lenguajes y Desarrollo de Soluciones IA	Apellidos:	
	Nombre:	

Actividad 4. Clasificación multiclase con Scikit Learn y TensorFlow sobre *dataset diamonds*

Objetivos

- Aprender el proceso de CRISP-DM de forma práctica con las librerías de Pandas, Seaborn, Scikit Learn y TensorFlow.
- Aprender a realizar un EDA univariante, bivariante, multivariante.
- Aprender a realizar una limpieza y preparación de datos.
- Aprender a implementar modelos de clasificación multiclase de Machine Learning y Deep Learning.

Pautas de elaboración

El ejercicio consiste en crear un modelo predictivo con scikit learn y TensorFlow para predecir la variable *cut* o corte de un diamante. El *dataset* será el de *diamonds* y está disponible públicamente en la librería *seaborn*.

Crear el código Python utilizando las librerías de Pandas, Seaborn, Scikit-Learn y TensorFlow Keras donde se cumplan los siguientes apartados:

- Cargar el *dataset* y estadísticas descriptivas.
- Limpieza de datos.
- EDAS univariante, bivariante y multivariante.
- Preparación de datos para el modelado.
- Modelado con Scikit Learn.
- Modelado con TensorFlow Keras.

Asignatura	Datos del alumno	Fecha
Lenguajes y Desarrollo de Soluciones IA	Apellidos:	
	Nombre:	

La columna para predecir es la columa *cut*, que es una variable categórica con más de 2 valores, por tanto, se trata de un ejercicio de clasificación multiclase. No se busca la máxima precisión para este ejercicio, se busca practicar los pasos comunes a la hora de crear modelos con scikit-learn y tensorflow.

Extensión y formato

- Entregar un archivo notebook (ipynb) con el siguiente formato:

diamonds_nombre_apellido.ipynb

- Si se detecta plagio en el *notebook* que copie parte de las respuestas de otro alumno, todos los alumnos involucrados obtendrán una calificación para la actividad de 0 puntos.
- Si se detecta contenido generado con modelos LLM como los de OpenAI o Anthropic se obtendrá una calificación para la actividad de 0 puntos.

Asignatura	Datos del alumno	Fecha
Lenguajes y Desarrollo de Soluciones IA	Apellidos:	
	Nombre:	

Rúbrica

Título de la actividad	Descripción	Puntuación máxima (puntos)	Peso %
1. Cargar el *dataset* y estadísticas descriptivas	Cargar el *dataset tips* con pandas. Realizar una exploración de estadísticas descriptivas de los datos con Pandas.	1	10%
2. Limpieza de datos	Detectar valores nulos. Corregir valores nulos. Corrección de tipos de datos. Eliminación de duplicados. Identificar y tratar Outliers.	2	20 %
3. EDAS univariante, bivariante y multivariante	Crear visualizaciones con *seaborn*: univariantes, bivariantes y multivariantes.	2	20%
4. Preparación de datos para el modelado	Codificación de variables categóricas utilizando la función get_dummies de Pandas. Escalar las columnas numéricas. Particionamiento de datos con train_test_split.	2	20%
5. Modelado	Probar varios modelos de regresión de Scikit Learn para predecir la columna tip del dataset. De cada uno extraer las métricas de regresión: MAE, RMSE, R2 y ver qué modelo es mejor.	3	30%
		10	**100 %**